

STAT3612 项目提案执行流程（Proposal Workflow）

1. 目标与范围

本阶段目标是完成项目提案所需的第一轮数据研究，并形成可复现、可分工、可汇报的工作流。

- 目标任务：基于 kaggle-dataset/ 完成数据理解、质量检查、初步特征研究与 baseline 设计。
- 最终交付：一份结构完整的 proposal（问题定义、数据描述、方法路线、实验计划、分工与排期）。
- 本文聚焦：第一步（5人团队如何研究 dataset）并给出具体执行细则。

2. 项目工作流（从数据到提案）

1. 数据审计（Data Audit）

- 统一主键：所有文件按 case_id 对齐。
- 检查 split：train.json、val.json、test.json。
- 检查字段缺失、异常值、路径可用性、标签分布。

2. 多源数据融合（Data Integration）

- 主表：以 JSON 为骨架。
- 外联：clinical_information/*.csv、original_raw_report/*.csv、radiomics_info/*/*.csv。
- 输出：统一样本级表（每行一个 case_id）。

3. 探索性分析（EDA）

- 结构化字段、文本报告、radiomics 分别建探索报告。
- 结论导向：识别可用特征、潜在泄漏、风险点。

4. Baseline 方案设计

- 先做可跑通 baseline（结构化+radiomics）。
- 固定验证方式与指标（建议 macro-F1 + accuracy）。

5. Proposal 撰写与答辩准备

- 汇总数据洞察、模型路线、实验计划、风险控制。
- 明确每位成员后续责任边界。

3. 五人分工（角色、任务、交付）

建议采用“角色负责制 + 交叉复核”。

成员A：数据质量与规范负责人

- 核心职责
 - 建立数据字典（字段解释、类型、取值范围）。
 - 做数据一致性检查：case_id 对齐、重复、缺失、异常值。
 - 输出路径映射规则（JSON 路径与实际目录差异）。
- 必交付
 - docs/data_dictionary.md
 - docs/data_quality_report.md
 - scripts/check_data_integrity.py（可选）

成员B：结构化临床特征负责人

- 核心职责
 - 分析 clinical_information 各字段分布。
 - 与标签（Overall_class）做统计关联。

- 给出结构化特征处理建议（编码、标准化、缺失策略）。
- 必交付
 - notebooks/eda_structured.ipynb
 - docs/structured_feature_plan.md

成员C：文本报告负责人

- 核心职责
 - 分析 report 与 raw_report 质量差异。
 - 文本长度、关键词、术语分布与类别关系探索。
 - 提出文本特征路线（TF-IDF 或 embedding）。
- 必交付
 - notebooks/eda_text.ipynb
 - docs/text_feature_plan.md

成员D：Radiomics 负责人

- 核心职责
 - 分析四个序列（ax_t1、ax_t1c、ax_t2、ax_t2f）特征分布。
 - 检查 radiomics 异常值、尺度差异、区分度。
 - 提出序列级特征融合方式（拼接/加权/筛选）。
- 必交付
 - notebooks/eda_radiomics.ipynb
 - docs/radiomics_feature_notes.md

成员E：Baseline 与评估负责人

- 核心职责
 - 构建端到端 baseline（训练、验证、预测、提交）。
 - 建立统一评估脚本与结果记录模板。
 - 维护实验日志（参数、版本、分数）。
- 必交付
 - notebooks/baseline_pipeline.ipynb
 - docs/experiment_log.md
 - outputs/sample_submission_v1.csv

4. 第一周执行节奏（建议）

Day 1：规范冻结

- 统一字段命名、目录结构、脚本运行方式。
- 定义“单一真相源”：case_id 为唯一 join key。
- 约定评估指标与随机种子。

Day 2-3：并行研究

- A/B/C/D 并行完成 EDA 与专题报告。
- E 先做可跑通 baseline（不追求最优，只追求稳定复现）。

Day 4：汇总与决策

- 合并 4 份 EDA 结论，形成 v1 特征清单。
- 确定 proposal 里的方法主线和备选路线。

Day 5: 提案定稿

- 补齐图表、实验计划、风险与备选方案。
- 进行一次组内模拟答辩（10-15 分钟）。

5. 操作SOP（每个人都要遵守）

1. **先审计再建模**：任何建模前必须完成数据质量检查。
2. **所有拼接必须按 `case_id`**：禁止按行序拼接。
3. **处理 CSV 列名 BOM**：读取后统一清洗列名（去 `\uffeff`）。
4. **路径可用性检查**：加载 `image_path` 前先做 `exists` 检查与修正映射。
5. **固定验证集**：只用 `train` 训练、`val` 验证，避免数据泄漏。
6. **记录每次实验**：至少记录特征版本、模型参数、分数、结论。

6. 团队协作机制（避免“各做各的”）

- 每日站会（10 分钟）
 - 昨天完成什么
 - 今天计划做什么
 - 当前阻塞是什么
- 同步节奏
 - 中午：进度短同步（文本）
 - 晚上：成果合并（代码/文档）
- 复核机制
 - 每个 notebook 至少由 1 人复核可复现性
 - 每份报告至少由 1 人复核结论与图表一致性

7. Proposal 建议目录结构

```
project-root/  
  docs/  
    data_dictionary.md  
    data_quality_report.md  
    structured_feature_plan.md  
    text_feature_plan.md  
    radiomics_feature_notes.md  
    experiment_log.md  
  notebooks/  
    eda_structured.ipynb  
    eda_text.ipynb  
    eda_radiomics.ipynb  
    baseline_pipeline.ipynb  
  outputs/  
    sample_submission_v1.csv  
  0. proposal_workflow.md
```

8. 评分导向建议（写入 proposal 可加分）

- 明确说明：类别不平衡问题与应对策略（`class weight` / `resampling` / `macro` 指标）。

- 明确说明：多模态融合策略（结构化 + 文本 + radiomics）的迭代路径。
 - 明确说明：可复现实验设计（固定 split、固定 seed、统一日志模板）。
 - 明确说明：风险与替代方案（文本效果弱时，先确保结构化+radiomics可交付）。
-

9. 第一阶段完成标准（Definition of Done）

满足以下条件即视为“第一步完成”：

- ☐ 已形成统一数据字典与质量报告。
- ☐ 三类 EDA（结构化/文本/radiomics）全部完成并可复现。
- ☐ baseline 可在本地端到端跑通并输出提交文件。
- ☐ proposal 的方法路线、实验计划、分工排期均已落文档。
- ☐ 团队每人有明确下一步任务与截止日期。